

LAPORAN TEKNIS PROYEK NUTRICITRA

ID Tim Capstone Project: CC26-PSU359

Judul Proyek : Nutri Citra: Food Detection and Nutrition Estimation
System Using YOLOv8

Tema yang Dipilih : Healthy Lives & Well Being

List Anggota :

1. CFCC200D6Y0334 - Hasan Suryadharma - Full-Stack Web Developer - **[Aktif]**
2. CFCC288D6Y0862 - Evan Azhar Hartana- Full-Stack Web Developer- **[Aktif]**
3. CACC012D6Y1490 - Faiz Nurrosyiddin - AI Engineer - **[Aktif]**
4. CACC012D6Y1491 - Amelia Candradewi - AI Engineer - **[Aktif]**
5. CDCC008D6X1798 - Talitha Widyadhana - Data Scientist - **[Aktif]**
6. CDCC008D6X2288 - Melani Sulistiawati - Data Scientist - **[Aktif]**

NutriCitra merupakan sistem berbasis *Computer Vision* yang didesain khusus untuk mendeteksi makanan tradisional khas Indonesia dan mengestimasi kandungan nutrisinya. Sistem mengintegrasikan model deteksi objek YOLOv8 dengan data nutrisi dari Tabel Komposisi Pangan Indonesia (TKPI) 2017, FatSecret serta Angka Kecukupan Gizi (AKG) berdasarkan Permenkes Nomor 28 Tahun 2019. Hasil deteksi makanan diolah menjadi informasi kalori, protein, lemak, dan karbohidrat yang dapat disesuaikan dengan profil pengguna.

1. PROBLEM DISCOVERY

1.1 Latar Belakang

Informasi kandungan nutrisi pada makanan kemasan umumnya tersedia dalam bentuk label gizi. Namun, sebagian besar makanan tradisional Indonesia tidak memiliki informasi nutrisi yang mudah diakses oleh masyarakat. Kondisi ini menyulitkan individu yang ingin memantau asupan energi dan zat gizi harian. Tingginya angka penyakit kronis seperti Diabetes, Obesitas, dan Hipertensi di Indonesia berakar pada rendahnya literasi gizi masyarakat. Makanan tradisional khas Indonesia (seperti bakso, Soto, Sate, dll) memiliki komposisi bahan yang kompleks dan bervariasi. Menghitung asupan nutrisi harian secara manual dari piring makan adalah proses yang sangat merepotkan dan tidak praktis bagi masyarakat awam. Hal ini pada akhirnya berkontribusi pada tidak terkontrolnya asupan kalori harian dan memicu risiko penyakit metabolik. Perkembangan teknologi *Computer Vision* membuka peluang untuk mengotomatisasi identifikasi makanan melalui citra digital. Dengan memanfaatkan model deteksi objek dan basis data nutrisi resmi, informasi gizi dapat diberikan secara lebih praktis kepada pengguna.

1.2 Rumusan Masalah

1. Bagaimana membangun sistem yang mampu mendeteksi makanan tradisional Indonesia dari citra digital?
2. Bagaimana mengintegrasikan hasil deteksi dengan informasi nutrisi berdasarkan TKPI 2017?
3. Bagaimana menyajikan informasi nutrisi yang relevan dengan kebutuhan pengguna berdasarkan AKG?

1.3 Tujuan Proyek

1. Mengembangkan sistem yang mampu mengakomodasi deteksi makanan dengan memanfaatkan *Computer Vision* berbasis YOLOv8.
2. Mengestimasi kandungan nutrisi makanan menggunakan data TKPI 2017, data kandungan nutrisi dari FatSecret, serta data Angka Kecukupan Gizi.
3. Menyediakan dashboard interaktif untuk eksplorasi nutrisi dan evaluasi model.

2. DATA UNDERSTANDING

2.1 Sumber Data

- Dataset Citra Makanan

Dataset dikumpulkan melalui proses scraping gambar dan mengunduhnya secara manual dari berbagai sumber daring yang selanjutnya dianotasi dengan menggunakan Roboflow.

- Dataset Nutrisi

Data nutrisi diperoleh dari Tabel Komposisi Pangan Indonesia (TKPI) 2017 yang diterbitkan oleh Kementerian Kesehatan Republik Indonesia.

- Dataset AKG

Data kebutuhan gizi harian menggunakan Angka Kecukupan Gizi (AKG) berdasarkan Permenkes Nomor 28 Tahun 2019.

2.2 Kelas Makanan

Sistem yang kami bangun hanya mampu mendeteksi 15 kelas makanan, karena keterbatasan waktu serta komponen penunjang model. Kelas makanan tersebut antara lain, sebagai berikut:

- Bakso
- Bubur Ayam
- Gado-gado
- Klepon
- Mie Goreng Jawa
- Nasi Goreng
- Nasi Gudeg
- Nasi Kuning
- Nasi Padang
- Pempek

- Rawon
- Rendang
- Sate Ayam
- Soto
- Tahu Gejrot

2.3 Data Dictionary

Data Nutrisi FatSecret

No	Nama Kolom	Tipe Data	Deskripsi	Contoh Nilai	Nilai Null?	Keterangan / Aturan Validasi
1	food_name	String	Nama makanan sebagai identifier utama	Soto Betawi	Tidak	Harus unik per entri. Digunakan sebagai foreign key ke food_label di data gambar.
2	serving_description	String	Deskripsi porsi sajian sesuai data FatSecret	1 Porsi (270 g)	Tidak	Format: '[jumlah] [unit] ([berat] g)'. Informatif, bukan untuk kalkulasi.
3	serving_size_g	Float	Berat satu porsi sajian dalam gram Null: 58	270.0	Ya	Range aktual: 15–478 g. NULL untuk 58 entri (buah TKPI). Perlu imputasi sebelum modeling.

4	calories	Integer	Kalori per satu porsi sajian (kkal)	363	Tidak	Range aktual: 5–664 kkal. Nilai 0 tidak boleh ada.
5	fat	Float	Total lemak per satu porsi sajian (gram)	23.90	Tidak	Range: ≥ 0 . Satuan: gram.
6	carbohydrate	Float	Total karbohidrat per satu porsi sajian (gram)	30.88	Tidak	Range: ≥ 0 . Satuan: gram.
7	protein	Float	Total protein per satu porsi sajian (gram)	10.93	Tidak	Range: ≥ 0 . Satuan: gram.
8	fatsecret_url	String	URL halaman FatSecret untuk makanan tersebut Null: 114	https://www.fatsecret.co.id/ ...	Ya	NULL untuk 114 entri (sumber TKPI tidak punya URL FatSecret). Verifikasi manual.
9	source	String	Sumber pengambilan data nutrisi	fatsecret_manual	Tidak	Nilai valid: 'fatsecret_manual' (scraping/manual FatSecret), 'tkpi_buah' (TKPI Kemenkes).

10	air	Float	Kadar air per 100g (%) Null: 175	NaN	Ya	Hanya terisi untuk sumber TKPI (114 entri). Satuan: gram per 100g.
11	serat	Float	Kandungan serat per sajian (gram) Null: 175	NaN	Ya	Hanya terisi untuk 114 entri (TKPI). Satuan: gram.
12	kategori	Float	Kode numerik kategori gizi Null: 175	NaN	Ya	Hanya terisi untuk entri dengan label_kategori. Sebaiknya dijadikan integer atau di-encode ulang.
13	label_kategori	String	Label kategori gizi makanan Null: 175	Padat Kalori & Energi	Ya	Nilai valid: 'Padat Kalori & Energi', 'Rendah Kalori & Tinggi Air', 'Serat Tinggi & Kalori Sedang'. NULL = 175 entri belum dikategorikan.
14	asal_daerah	String	Asal daerah/provinsi makanan	DKI Jakarta	Tidak	Nilai 'Umum' untuk makanan nasional/tidak spesifik daerah. Bisa dipakai sebagai fitur regional.

No	Nama Kolom	Tipe Data	Deskripsi	Contoh Nilai	Nilai Null?	Keterangan / Aturan Validasi
1	usia	String	Kelompok usia dalam format teks	0 bulan / 5 tahun / 80+ tahun	Tidak	Nilai: '0 bulan' s/d '11 bulan', '1 tahun' s/d '79 tahun', '80+ tahun'. Jika dipakai untuk join/filter, konversi ke numerik terlebih dahulu.
2	gender	Integer (dummy)	Jenis kelamin dalam kode biner	0	Tidak	0 = Laki-laki, 1 = Perempuan. Nilai selain 0/1 tidak valid.
3	hamil_1_13	Integer (dummy)	Kondisi hamil trimester 1 (minggu 1–13)	0	Tidak	0 = Tidak hamil, 1 = Hamil minggu 1–13. Hanya relevan untuk gender=1 (Perempuan).
4	hamil_14_27	Integer (dummy)	Kondisi hamil trimester 2 (minggu 14–27)	0	Tidak	0 = Tidak, 1 = Hamil minggu 14–27. Hanya untuk gender=1.
5	hamil_28_41	Integer (dummy)	Kondisi hamil trimester 3 (minggu 28–41)	0	Tidak	0 = Tidak, 1 = Hamil minggu 28–41. Hanya untuk gender=1.

6	menyusui_6bl_pertama	Integer (dummy)	Kondisi menyusui 6 bulan pertama	0	Tidak	0 = Tidak, 1 = Menyusui 6 bulan pertama. Hanya untuk gender=1.
7	menyusui_6bl_kedua	Integer (dummy)	Kondisi menyusui 6 bulan kedua	0	Tidak	0 = Tidak, 1 = Menyusui 6 bulan kedua. Hanya untuk gender=1.
8	energi_kkal	Integer	Kebutuhan energi harian (kkal/hari)	550	Tidak	Range aktual: 550–2650 kkal. Digunakan sebagai referensi kecukupan kalori harian per profil pengguna.
9	protein_g	Integer	Kebutuhan protein harian (gram/hari)	9	Tidak	Range aktual: 9–95 g.
10	lemak_total_g	Float	Kebutuhan lemak total harian (gram/hari)	31.0	Tidak	Range aktual: 31.0–85.0 g.
11	karbohidrat_g	Integer	Kebutuhan karbohidrat harian (gram/hari)	59	Tidak	Range aktual: 59–430 g.

3. DATA PREPARATION

3.1 Akuisisi Data

Dalam hal akuisisi data gambar tim kami khususnya tim data science menggunakan cara manual yaitu dengan mengunduhnya melalui berbagai sumber seperti Google dan Pinterest, tetapi sebelumnya telah mencoba melakukan *scraping* dengan menggunakan bantuan Python akan tetapi hasilnya tidak maksimal karena terkendala dengan izin

3.2 Anotasi Data

Setelah semua data gambar yang diperlukan telah terkumpul lalu tim kami menggunakan pihak ketiga, yaitu Roboflow untuk melakukan bounding box. Selain itu, dengan menggunakan Roboflow kami dapat menggunakan fitur gratis seperti meng-augmentasikan data gambar tersebut sehingga lebih banyak variasi yang dapat membantu meningkatkan akurasi model.

3.3 Data Cleaning

- Penghapusan gambar duplikat
- Pemeriksaan kualitas gambar
- Penyamaan format data

3.4 Pembagian Dataset

- Training set 70%
- Validation set 20%
- Testing set 10%

3.5 Integrasi Data Nutrisi

Data nutrisi tidak diintegrasikan secara langsung ke dalam model deteksi, melainkan dikelola secara terpisah sebagai komponen database yang digunakan oleh dashboard analitik dan aplikasi web. Model YOLOv8 hanya bertugas

mendeteksi citra digital. Kelas makanan yang telah didefinisikan sejak tahap anotasi di Roboflow berfungsi sebagai penghubung antara sistem deteksi dan database nutrisi pada sisi aplikasi. Database nutrisi yang digunakan dalam dashboard dibangun dari dua sumber utama. Pertama, data FatSecret yang diperoleh melalui *scraping* dan input manual untuk makanan yang tersedia secara daring. Kedua, Tabel Komposisi Pangan Indonesia (TKPI) 2017 sebagai sumber alternatif untuk makanan yang tidak tersedia di FatSecret. Total database mencakup 289 makanan Indonesia dengan informasi kalori, protein, lemak, dan karbohidrat per porsi standar masing-masing makanan. Sedangkan data nutrisi tersebut kemudian dikalkulasikan terhadap Angka Kecukupan Gizi (AKG) sesuai profil pengguna berdasarkan Permenkes Nomor 28 Tahun 2019, dan disajikan secara interaktif melalui dashboard Streamlit.

4. MODELING

4.1 Pemilihan Algoritma

Model yang digunakan dalam sistem yang kami bangun adalah YOLOv8 versi nano (YOLOv8n) karena memiliki performa tinggi pada tugas deteksi objek secara real-time dengan kebutuhan komputasi yang relatif ringan. YOLOv8 merupakan generasi terbaru dari keluarga YOLO (*You Only Look Once*) yang dikembangkan oleh Ultralytics, dengan arsitektur yang dioptimalkan untuk kecepatan dan akurasi secara bersamaan. Pemilihan varian nano didasarkan pada pertimbangan efisiensi sumber daya selama proses pelatihan di lingkungan Google Colab dengan akselerasi GPU.

4.2 Konfigurasi Training

Proses pelatihan dilakukan menggunakan framework Ultralytics di Google Colab dengan konfigurasi sebagai berikut:

Parameter	Nilai
Base Model	YOLOv8n (pre-trained)

Jumlah Epoch	50
Batch Size	16
Image Size	640 x 640 px
Optimizer	AdamW
Learning Rate	0.02

Selain konfigurasi standar, diterapkan pula mekanisme *early stopping* berbasis *custom callback* yang menghentikan proses pelatihan secara otomatis apabila nilai mAP50 sudah mencapai atau melampaui 0.98. Hal ini dilakukan untuk mencegah *overfitting* sekaligus menghemat waktu komputasi.

4.3 Model Sistem Rekomendasi (TensorFlow)

Sistem rekomendasi buah dibangun menggunakan model klasifikasi berbasis TensorFlow yang dilatih menggunakan Custom Training Loop. Model menerima input berupa sisa kuota kalori harian pengguna dan menghasilkan ID kategori gizi dengan probabilitas tertinggi. Berdasarkan kategori tersebut, sistem melakukan smart random sampling pada database buah untuk menyajikan 3 rekomendasi yang dipersonalisasi. Model mencapai akurasi validasi sebesar 99,60% dengan MAE 0,0112 hanya dalam satu epoch pelatihan.

4.4 Evaluasi Model

Evaluasi model dilakukan menggunakan empat metrik utama yang umum dipakai pada tugas deteksi objek:

- **Precision** mengukur proporsi prediksi positif yang benar-benar merupakan objek yang dimaksud. Nilai tinggi menunjukkan model jarang menghasilkan *false positive*.
- **Recall** mengukur proporsi objek yang seharusnya terdeteksi dan berhasil ditemukan oleh model. Nilai tinggi menunjukkan model jarang melewatkan objek (*false negative*).

- **mAP50** (*mean Average Precision* pada IoU threshold 0.5) merupakan metrik utama yang merangkum keseimbangan precision dan recall pada seluruh kelas. Nilai ini menjadi acuan utama kualitas model secara keseluruhan.
- **mAP50-95** merupakan rata-rata mAP pada berbagai IoU threshold (0.5 hingga 0.95, dengan step 0.05), sehingga memberikan gambaran performa yang lebih ketat terhadap ketepatan lokalisasi bounding box.

5. HASIL DAN PEMBAHASAN

5.1 Hasil Evaluasi Model

Model YOLOv8 yang dilatih pada dataset 15 kelas makanan tradisional khas Indonesia menghasilkan performa sebagai berikut pada data validasi:

Metrik	Nilai
Total gambar	4632
Precision	0.985
Recall	0.977
mAP50	0.987

Hasil ini menunjukkan bahwa model mampu mendeteksi makanan dengan tingkat akurasi yang sangat tinggi dan konsisten di seluruh kelas. Visualisasi evaluasi yang dihasilkan selama proses pelatihan meliputi Confusion Matrix, Precision-Recall Curve, F1 Curve, dan Training Result Curve yang memperlihatkan konvergensi model sebelum epoch ke-50.

5.2 Analisis Performa Per Kelas


Tabel berikut merangkum hasil evaluasi model per kelas makanan:

Kelas	Images	Precision	Recall	mAP50	mAP50-95
Bakso	92	0.957	0.833	0.947	0.727
Bubur Ayam	60	0.971	0.959	0.983	0.906
Gado-gado	71	0.997	0.986	0.995	0.936
Klepon	63	0.978	0.962	0.993	0.827
Mie Goreng Jawa	56	0.977	1.000	0.994	0.935
Nasi Goreng	54	1.000	0.995	0.995	0.954
Nasi Gudeg	32	0.994	1.000	0.995	0.958
Nasi Kuning	31	0.994	1.000	0.995	0.949
Nasi Padang	57	0.996	0.983	0.985	0.962
Pempek	60	0.950	0.952	0.946	0.866

Rawon	51	0.998	1.000	0.995	0.826
Rendang	55	0.979	0.982	0.992	0.949
Sate Ayam	55	1.000	1.000	0.995	0.908
Soto	60	0.994	1.000	0.995	0.942
Tahu Gejrot	56	0.995	1.000	0.995	0.942

Kelas dengan performa tertinggi adalah nasi goreng, sate ayam, dan tahu gejrot yang ketiganya mencapai mAP50 sebesar 0.995. Kelas-kelas ini memiliki karakteristik visual yang cukup khas dan berbeda dari kelas lainnya sehingga lebih mudah diidentifikasi oleh model. Sedangkan, kelas bakso dan pempek mencatatkan performa relatif lebih rendah dibanding kelas lainnya, masing-masing dengan mAP50 sebesar 0.947 dan 0.946. Kedua kelas ini memiliki kemiripan visual yang cukup tinggi, yaitu berbentuk bulat, berwarna coklat keabu-abuan, dan sering muncul dalam konteks penyajian yang serupa hal ini menyebabkan model lebih sering keliru pada kedua kelas tersebut. Khusus pada kelas bakso, nilai *recall* yang lebih rendah (0.833) mengindikasikan bahwa model masih melewatkan sebagian objek bakso yang seharusnya terdeteksi, terutama pada kondisi penyajian yang tidak umum seperti bakso dalam kuah gelap atau bakso yang sebagian tertutup bahan lain.

5.3 Hubungan Jumlah Data dan Akurasi



Analisis korelasi antara jumlah gambar pelatihan per kelas dan nilai mAP50 menunjukkan hubungan yang lemah. Kelas bakso justru memiliki jumlah gambar terbanyak (92 gambar) namun mencatatkan mAP50 terendah, sementara kelas nasi gudeg dan nasi kuning yang memiliki gambar jauh lebih sedikit (masing-masing 32 dan 31 gambar) berhasil mencapai mAP50 sebesar 0.995. Pola ini mengindikasikan bahwa setelah jumlah data melampaui ambang batas tertentu, faktor yang lebih menentukan performa model bukan lagi penambahan kuantitas data, melainkan keragaman visual gambar yang mencakup variasi sudut pengambilan, pencahayaan, latar belakang, dan kondisi penyajian. Dengan demikian, pada pengembangan model berikutnya, upaya peningkatan performa sebaiknya lebih diarahkan pada peningkatan kualitas dan keragaman data dibanding penambahan jumlah gambar secara masif.

6. DASHBOARD DAN BUSINESS INSIGHT

Dashboard NutriCitra dibangun menggunakan Streamlit dan terdiri dari tiga tab utama: Kalkulator Nutrisi, Eksplorasi Makanan, dan Performa Model. Dashboard ini mengintegrasikan database 289 makanan Indonesia dengan data AKG Permenkes No. 28 Tahun 2019 untuk menghasilkan analisis gizi yang dapat dipersonalisasi berdasarkan profil pengguna.

Business Question 1

Bagaimana kontribusi satu porsi makanan terhadap kebutuhan gizi harian pengguna?

- Visualisasi: Tab Kalkulator Nutrisi menampilkan bar chart persentase AKG untuk kalori, protein, lemak, dan karbohidrat. Pengguna dapat menyesuaikan berat porsi melalui slider serta memilih profil usia, jenis kelamin, dan kondisi fisiologis melalui panel sidebar.
- Temuan: Informasi nutrisi dapat dipersonalisasi secara dinamis berdasarkan profil pengguna. Sebagai acuan, batas wajar kontribusi satu kali makan adalah 25% dari total AKG harian. Sistem secara otomatis memberikan interpretasi apabila suatu makanan melampaui batas tersebut, sehingga pengguna dapat mempertimbangkan penyesuaian porsi atau kombinasi menu hariannya.

Business Question 2

Makanan apa yang memiliki kandungan kalori, protein, lemak, atau karbohidrat tertinggi?

- Visualisasi: Tab Eksplorasi Makanan menampilkan bar chart horizontal yang dapat diurutkan berdasarkan salah satu dari empat nutrisi utama, dilengkapi filter kategori kalori dan asal daerah.
- Temuan: Berdasarkan database 289 makanan, makanan dengan kandungan nutrisi tertinggi bervariasi tergantung metrik yang digunakan. Perlu dicatat bahwa perbedaan nilai nutrisi antar kelas makanan sebagian dipengaruhi oleh perbedaan ukuran porsi yang mana makanan dicatat per porsi besar seperti satu piring atau satu mangkuk cenderung memiliki nilai absolut lebih tinggi dibanding yang dicatat per item kecil seperti satu tusuk atau satu buah.

Business Question 3

Bagaimana distribusi kategori kalori makanan yang dianalisis?

- Visualisasi: Pie chart distribusi 289 makanan berdasarkan tiga kategori: Rendah (<200 kkal), Sedang ($200-400$ kkal), dan Tinggi (≥ 400 kkal).
- Temuan: Sebagian besar makanan dalam database termasuk kategori rendah kalori per porsi. Hal ini bukan berarti makanan tersebut ringan secara nutrisi, melainkan karena banyak data dicatat dalam satuan per item kecil seperti satu tusuk sate atau satu buah klepon. Makanan berkategori tinggi kalori umumnya adalah hidangan nasi lengkap yang mencakup nasi, lauk, dan pelengkap dalam satu porsi.

Business Question 4

Makanan apa yang paling efisien sebagai sumber protein?

- Visualisasi: Bar chart horizontal Indeks Efisiensi Protein, dihitung sebagai gram protein per 100 kkal.
- Temuan: Makanan berbahan dasar telur, ayam, atau ikan umumnya mendominasi posisi teratas indeks efisiensi protein karena kandungan proteinnya tinggi tanpa disertai lemak atau karbohidrat berlebihan. Sebaliknya, makanan berbasis tepung dan gula seperti kue tradisional memiliki indeks sangat rendah karena hampir seluruh kalornya berasal dari karbohidrat. Indeks ini relevan bagi individu yang ingin meningkatkan asupan protein tanpa menambah kalori secara signifikan.

Business Question 5

Apakah jumlah gambar training mempengaruhi performa model?

- Visualisasi: Scatter plot jumlah gambar per kelas vs nilai mAP50, dengan ukuran titik proporsional terhadap jumlah gambar.
- Temuan: Hubungan antara jumlah gambar dan mAP50 terbukti lemah secara statistik. Kelas dengan gambar terbanyak justru tidak selalu mencapai mAP50 tertinggi. Ini menegaskan bahwa keragaman visual data lebih berpengaruh terhadap akurasi dibandingkan volume data semata.

7. ANALISIS SWOT

- Kekuatan (Strengths)

1. Sistem yang tim kami bangun mengintegrasikan deteksi makanan dan informasi gizi dimana tidak hanya mengenali jenis makanan, tetapi juga menerjemahkan hasil deteksi menjadi estimasi kalori dan nutrisi yang relevan bagi pengguna.
2. Data yang kami kumpulkan dan gunakan berasal dari TKPI 2017 dan kebutuhan gizi menggunakan AKG Permenkes No. 28 Tahun 2019 sehingga memiliki dasar ilmiah yang jelas.
3. Berdasarkan data yang digunakan kami dapat mengambil beberapa informasi nutrisi yang dapat disesuaikan dengan usia, jenis kelamin, kondisi kehamilan dan menyusui pada wanita sehingga lebih informatif dibanding sekadar menampilkan kalori.
4. Model yang tim kami gunakan, yaitu model YOLOv8 mencapai mAP50 sekitar 0,987 sehingga mampu mendeteksi sebagian besar kelas makanan dengan baik.
5. NutriCitra dirancang khusus untuk makanan tradisional Indonesia yang mana kita seringkali memakan makanan tersebut, tetapi kita tidak mengetahui kandungan gizi yang ada dalam makanan tersebut.

- Kelemahan (Weaknesses)

1. Jumlah kelas makanan yang masih terbatas, sistem yang kami bangun hanya mengenali 15 jenis makanan sehingga belum mencakup keragaman kuliner Indonesia.
2. Belum dapat memperkirakan porsi secara otomatis hal ini mengakibatkan pengguna masih harus memasukkan estimasi berat makanan secara manual.

3. Estimasi kandungan nutrisi dapat berbeda bergantung dengan resep, bahan, dan metode pengolahan masing-masing daerah.
 4. Performa tidak merata terhadap semua kelas, hal ini ditunjukkan pada beberapa makanan, seperti bakso dan pempek yang memiliki performa lebih rendah dibanding kelas lainnya.
 5. Sistem yang kami bangun belum mendukung multi-food secara kompleks dimana jika satu gambar berisi banyak makanan dengan tumpang tindih tinggi, estimasi dapat menjadi kurang akurat. Hal ini dikarenakan terbatasnya keilmuan yang kami miliki serta waktu yang cukup terbatas untuk menyelesaikan proyek ini.
- Peluang (Opportunities)
 1. Dengan adanya sistem yang kami bangun, kami berharap dapat meningkatkan kesadaran masyarakat terhadap pola makan sehat dengan mulai memperhatikan kalori dan nutrisi harian.
 2. Potensi untuk mengintegrasikan dengan aplikasi kesehatan yang mana sistem dapat dikembangkan sehingga adanya fitur pendukung diet, manajemen berat badan, atau pencatatan konsumsi makanan.
 3. Penambahan jumlah kelas makanan yang lebih banyak, dataset dapat diperluas mencakup ratusan makanan khas Indonesia.
 4. Sistem yang kami bangun dapat dikembangkan atau berkolaborasi dengan sektor kesehatan dan pendidikan yang mana dapat digunakan untuk edukasi gizi di sekolah, kampus, atau fasilitas kesehatan.
 - Ancaman (Threats)

1. Kami sadar bahwa sistem yang kami bangun sarat akan variasi visual makanan yang sangat tinggi karena makanan yang sama dapat memiliki tampilan berbeda tergantung daerah, resep, dan penyajian.
2. Kandungan nutrisi aktual mungkin berbeda dari nilai TKPI yang digunakan.
3. Semakin berkembangnya teknologi khususnya *Artificial Intelligence* (AI) maka semakin banyak pula kompetitor dengan teknologi serupa yang mulai mengembangkan *food recognition* berbasis AI.
4. Sistem yang kami bangun mengandalkan deteksi objek sehingga memiliki ketergantungan pada kualitas gambar yang mana pencahayaan, sudut pengambilan, atau objek tertutup sangat mempengaruhi dalam menurunkan akurasi model.
5. Pengguna dapat menganggap hasil estimasi yang diberikan oleh sistem kami sebagai nilai pasti, padahal sistem memberikan estimasi berdasarkan data referensi.

8. KESIMPULAN DAN REKOMENDASI

Kesimpulan

Model YOLOv8n berhasil mendeteksi 15 jenis makanan tradisional khas Indonesia dengan performa yang sangat baik, mencapai rata-rata mAP50 sebesar 0.987 dan Precision 0.985 pada data validasi. Seluruh kelas memperoleh mAP50 di atas 0.94, menunjukkan konsistensi performa yang tinggi antar kelas. Kelas bakso dan pempek mencatatkan performa relatif lebih rendah akibat kemiripan visual keduanya, hal ini terjadi bukan karena kekurangan data melainkan oleh lemahnya korelasi antara jumlah gambar pelatihan dan nilai mAP50. Integrasi database

makanan Indonesia yang bersumber dari FatSecret dan TKPI 2017, dikombinasikan dengan data AKG berdasarkan Permenkes Nomor 28 Tahun 2019, memungkinkan sistem memberikan informasi nutrisi yang dapat dipersonalisasi berdasarkan usia, jenis kelamin, dan kondisi fisiologis pengguna. Dashboard Streamlit yang dikembangkan berhasil menjawab lima pertanyaan bisnis utama terkait kontribusi nutrisi per porsi, perbandingan profil gizi antarmakanan, distribusi kategori kalori, efisiensi protein, serta hubungan antara volume data dan akurasi model.

Rekomendasi

1. Menambah jumlah dan keragaman kelas makanan. Sistem saat ini hanya mengakomodasi 15 kelas, sementara kekayaan kuliner Indonesia jauh lebih luas. Penambahan kelas sebaiknya disertai dengan pengumpulan data yang beragam secara visual, bukan hanya memperbanyak jumlah gambar dengan kondisi yang serupa.
2. Meningkatkan kualitas data pada kelas bermasalah. Kelas bakso perlu mendapat perhatian khusus dengan menambahkan variasi gambar yang lebih kompleks guna meningkatkan nilai *recall* yang saat ini masih 0.833.
3. Mengembangkan estimasi porsi otomatis. Saat ini berat porsi masih diinput manual oleh pengguna melalui slider. Integrasi dengan estimasi volume berbasis *depth estimation* atau referensi objek akan membuat kalkulasi nutrisi jauh lebih akurat dan praktis.
4. Mengimplementasikan sistem pada perangkat mobile. Agar dapat digunakan secara langsung saat makan, sistem perlu dikemas dalam aplikasi mobile yang memungkinkan deteksi makanan secara real-time melalui kamera perangkat.
5. Menambahkan fitur pencatatan konsumsi harian. Fitur log harian akan memungkinkan pengguna memantau akumulasi asupan kalori dan zat gizi sepanjang hari, sehingga sistem tidak hanya informatif per porsi tetapi juga berguna untuk manajemen pola makan jangka panjang.

Sistem dapat diakses melalui <https://nutri-citra-project-6eik.vercel.app>

